

Whisper ASR 幻觉问题研究

从问题发现到解决方案

ASR 论文阅读报告

2025 年 12 月 31 日

汇报人：王宇东

目录

背景介绍

Whisper 幻觉问题

幻觉现象深入调查

Calm-Whisper 解决方案

总结与展望

背景介绍


Whisper 模型概述

OpenAI Whisper (2022)

- **训练数据:** 680,000 小时多语言弱监督数据
- **架构:** Encoder-Decoder Transformer
- **多任务:** 语音识别、翻译、语言识别、VAD
- **多语言:** 支持 96+ 种语言

核心优势

- 零样本迁移能力强
- 无需针对特定数据集微调
- 接近人类水平的准确率




图源: Radford et al., 2022

Whisper 的卓越性能


零样本鲁棒性

- LibriSpeech test-clean: 2.5% WER
- 相比 wav2vec 2.0 平均错误率降低 55.2%
- 在噪声环境下表现优异




模型规模与性能关系

多任务格式




特殊 token 指定:

Whisper 的鲁棒性与人类水平



零样本 Whisper 接近人类鲁棒性



噪声环境下 Whisper 表现更优

Whisper 幻觉问题

什么是 ASR 幻觉？

定义

ASR 幻觉是指模型生成与原始音频没有语音或语义联系的文本输出。

幻觉类型

- 非语音幻觉: 对纯噪声生成文字
- 循环幻觉 (Looping): 重复之前的文本
- 内容幻觉: 生成与音频无关的内容

产生原因

- 自回归解码的累积误差
- 训练数据中的噪声和偏差
- 模型对模糊输入的过度自信

危害

部分幻觉可能包含**暴力、色情**等有害内容，在实际应用中造成严重问题！

幻觉示例

非语音幻觉案例

输入音频 Whisper 输出

- | 输入音频 | Whisper 输出 |
|--------|----------------------------|
| ▷ 狗叫声 | "Thank you for watching!" |
| ▷ 汽车引擎 | "Please subscribe..." |
| ▷ 纯静音 | "I'm going to show you..." |

这些输出与音频内容完全无关

循环幻觉案例

实际语音: "Hello"

"Hello hello hello hello hello hello
hello hello..."

有害内容幻觉

研究发现部分幻觉包含:

- 暴力描述
- 色情内容
- 种族歧视言论

来源: Koenecke et al., PNAS 2020

whisper-large-v3 vs parakeet-tdt-0.6b-v3



Associate Producers IVY XIAO
WE MAKE MOVIES, INC.

Cinematographer BRIAN TANG
Aerial Cinematographer JOSEPH YAO
Assistant Camera MICAH FUCUS
Production Sound ANNE GENG
Production Assistant PRICILA PEREZ

Production Designer KRISTINA WONG
Assistant Production Designers CHRISTINA DIAL
CHINA LAU
Hair & Makeup Artist LIVI IN PARK

woman : Hey, do you like the soulmates?

woman : I wonder if you have more than one, or they're like different kinds.

man: Yeah, I think so.



09:01:040 --> 09:04:040

Hey, do you like the soulmates?

09:05:540 --> 09:10:040

I wonder if you have more than one, or if there are different kinds?

09:13:540 --> 09:15:540

Yeah, I think so.

09:20:040 --> 09:25:040

Translated by Hua Chenyu English Subs

09:50:040 --> 09:55:040

Subtitles brought to you by the Figaro Cuisine Squad at Viki



00:09:00.799 --> 00:09:03.440

Hey, do you like the soulmates?

00:09:05.360 --> 00:09:09.519

I wonder if you have more than one, or if they're like different kinds.

00:09:13.440 --> 00:09:14.960

Yeah, I think so.


Whisper tends to produce hallucinations in segments without speech, especially in background music segments, whereas Parakeet performs much better.

非语音幻觉的严重性

UrbanSound8K 测试结果

(城市环境声音数据集：警笛、狗叫、引擎声等)

模型	幻觉率
Whisper-large-v3	99.97%
Conformer-CTC-large	13.52%



图源: Wang et al., Calm-Whisper, 2025

几乎所有非语音音频都会触发幻觉

幻觉现象深入调查

评估指标介绍

语音识别性能指标

WER (Word Error Rate)

$$WER = \frac{S + D + I}{N} \times 100\%$$

- S = 替换词数
- D = 删减词数
- I = 插入词数
- N = 参考文本总词数

WER 越低越好, Whisper large: ~2-4%

幻觉评估指标

幻觉率 (Hallucination Rate)

$$HR = \frac{\text{产生幻觉的样本数}}{\text{总样本数}} \times 100\%$$

循环率 (Looping Rate)

检测输出中重复片段的比例

其他指标

- CER: 字符错误率
- Top-K 率: 最常见 K 种幻觉的占比

实验设置

- 数据集: AudioSet + Musan + UrbanSound8K + FSD50K
- 总计 301,317 个非语音音频文件
- 移除所有可能包含语音的音频

实验结果

- 幻觉发生率: 40.3%
- 其中 9.1% 涉及循环 (looping)
- 生成 41,231 种不同输出
- 67% 的幻觉来自 1,270 个重复短语

关键发现

- 超过 35% 的幻觉是两个短语
- Top 10 占所有幻觉的一半以上
- 与 YouTube 字幕训练数据相关

音频长度对幻觉的影响

长度 [s]	幻觉率	循环率	Top30 率
原始	70.5%	18.5%	76.7%
1	52.1%	0.7%	84.2%
10	11.6%	3.4%	47.1%
20	27.4%	4.8%	47.5%
30	62.3%	9.6%	84.6%

* Top30 = 最常见的 30 种幻觉

观察结论

- 10 秒左右幻觉率**最低**
- 极短 (1s) 和较长 (30s) 音频幻觉率高
- 30 秒是 Whisper 的解码窗口边界
- 音频内容与幻觉内容关联性弱

幻觉词袋 (Bag of Hallucinations)

构建方法

1. 收集所有非语音音频的转录结果
2. 使用 n-gram 语言模型计算概率
3. 过滤条件:
 - log 概率 < -10
 - 出现次数 > 4

典型 BoH 内容

- "thanks for watching"
- "thank you for watching"
- "subtitles by the amara org community"
- "i'm not sure what i'm doing here"

幻觉内容	占比	n-gram
thank you	24.76%	-9.22
thanks for watching	10.32%	-13.32
so	3.80%	-7.76
thank you for watching	2.58%	-12.42
the	2.50%	-6.67

高亮行属于 BoH (低概率但高频)

后处理缓解方案

方法流程

1. **去循环 (Delooping)**: 检测并移除重复文本
2. **BoH 移除**: 使用 Aho-Corasick 算法匹配并删除
3. (可选) 强制音素对齐验证

对比方法

- Whisper 参数调整 (beam size, threshold)
- VAD 预处理 (WebRTC, SileroVAD)
- 去噪 (DCCRN) — 效果不佳

方法	WER
无处理	104.8%
beam size 1	107.2%
hall. threshold 20	39.8%
WebRTC VAD	68.3%
SileroVAD	8.0%
Deloop + BoH	17.1%
SileroVAD + Deloop + BoH	6.5%

组合方法效果最佳

Calm-Whisper 解决方案

核心假设: Crazy Heads

假设


Whisper 解码器中的某些自注意力头对噪声特别敏感，是导致幻觉的主要原因。

实验方法

- 逐个掩码 20 个注意力头
- 测量幻觉率变化
- 识别“crazy heads”

发现

- 8 个头导致幻觉增加
- 掩码 #1 头：幻觉率降 30%+
- 其余 12 个头抑制幻觉



图源: Wang et al., Calm-Whisper, 2025

多头掩码实验

掩码头	幻觉率	WER test-clean	WER test-other
无掩码	99.97%	2.12%	4.07%
#1, #6	50.16%	5.70%	5.48%
#1, #11	70.03%	3.80%	6.07%
#6, #11	57.08%	2.37%	4.66%
#1, #6, #11	24.10%	3.57%	5.98%
#0, #1, #6, #11	28.91%	15.87%	21.39%

关键发现

- 三头 (#1, #6, #11) 贡献 75%+ 的幻觉
- 掩码四头会严重损害识别性能

权衡

- 掩码三头是最佳平衡点
- 但仍有 WER 损失
- 需要更好的解决方案


Calm-Down 微调策略

核心思路

保留所有头进行推理，但只对 crazy heads 进行微调

训练设置

- 冻结**: 除 #1, #6, #11 外的所有参数
- 数据**: 105 小时非语音音频
 - AudioSet (无语音部分)
 - DEMAND
 - Musan (音乐 + 噪声)
- 标签**: 空字符串
- 超参**: batch=128, lr= 10^{-6}



图源: Wang et al., Calm-Whisper, 2025

Calm-Whisper 实验结果

模型	幻觉率	WER test-clean	WER test-other
原始 (Non-Mask)	99.97%	2.12%	4.07%
掩码三头 (Mask)	24.10%	3.57%	5.98%
ft-decoder-3epochs	0.01%	100%	100%
ft-3heads-3epochs	69.79%	2.16%	4.08%
Calm-Whisper (5 epochs)	15.51%	2.19%	4.13%

关键结论

- 幻觉率下降 84%
- WER 仅增加 ~0.07%
- 长幻觉大幅减少


对比：全解码器微调

- 幻觉率降至 0.01%
- WER 翻升至 100%
- 完全失效

局限性

- 仍有 15% 幻觉率
- 仅验证 large-v3
- 需要额外训练资源

微调深度的影响



图源: Wang et al., Calm-Whisper, 2025

观察


- 幻觉率: 初期快速下降, 后平缓
- WER: 初期缓慢上升, 后加速
- 5 epochs 是最佳平衡点

为什么有效?

- 非微调头保留原始能力
- 提供必要的冗余和鲁棒性

总结与展望

三篇论文的关系



Whisper 原论文

- 展示弱监督的潜力
- 暴露幻觉问题

ICASSP 调查

- 量化幻觉现象
- 提出后处理方案

Calm-Whisper

- 定位问题根源
- 从模型内部解决

方法对比

方法	类型	幻觉降低	WER 影响	复杂度
VAD 预处理	前处理	中等	低	低
参数调整	推理时	低	低	低
BoH 后处理	后处理	高	可能误删	中
Calm-Whisper	模型微调	很高	极低	中
组合方案	多阶段	最高	低	高

推荐策略

- 对准确性要求高: Calm-Whisper + VAD + BoH
- 快速部署: VAD 预处理 + BoH 后处理
- 研究探索: 注意力头分析 + 针对性微调

未来研究方向

模型层面

- 更深入的注意力头分析
- 其他架构的幻觉研究
- 多语言幻觉特性
- 强化学习优化解码

数据层面

- 更好的训练数据过滤
- 对抗性训练
- 多样化非语音数据

应用层面

- 实时幻觉检测
- 置信度校准
- 工业场景适配

开放问题

- 为什么特定头容易幻觉?
- 如何预测幻觉发生?
- 幻觉与模型能力的关系?

核心要点

1. Whisper 在非语音音频上存在严重幻觉问题 (接近 100%)
2. 幻觉主要由解码器中的少数注意力头引起
3. Calm-Whisper 通过定向微调将幻觉率降低 84%，同时保持识别性能
4. 后处理方法可作为补充安全措施

实践建议

- 工业部署需要幻觉防护
- 多种方法组合效果最佳
- 关注有害内容过滤

研究启示

- 大模型的可解释性研究
- 局部微调的有效性
- 数据质量的重要性

谢谢！

Q & A

参考文献 i

1. Radford, A., et al. (2022). *Robust Speech Recognition via Large-Scale Weak Supervision*. ICML 2022.
2. Wang, Y., et al. (2025). *Calm-Whisper: Reduce Whisper Hallucination On Non-Speech By Calming Crazy Heads Down*. Interspeech 2025.
3. Barański, M., et al. (2025). *Investigation of Whisper ASR Hallucinations Induced by Non-Speech Audio*. ICASSP 2025.
4. Koenecke, A., et al. (2020). *Racial disparities in automated speech recognition*. PNAS.
5. Peng, Y., et al. (2024). *Owsm v3. 1: Better and faster open whisper-style speech models based on e-branchformer*. arXiv.